資料工程 External sort

403410033

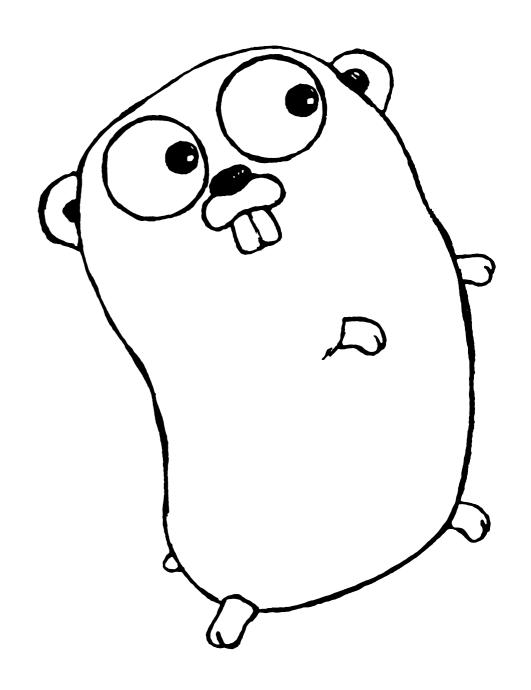
資工四

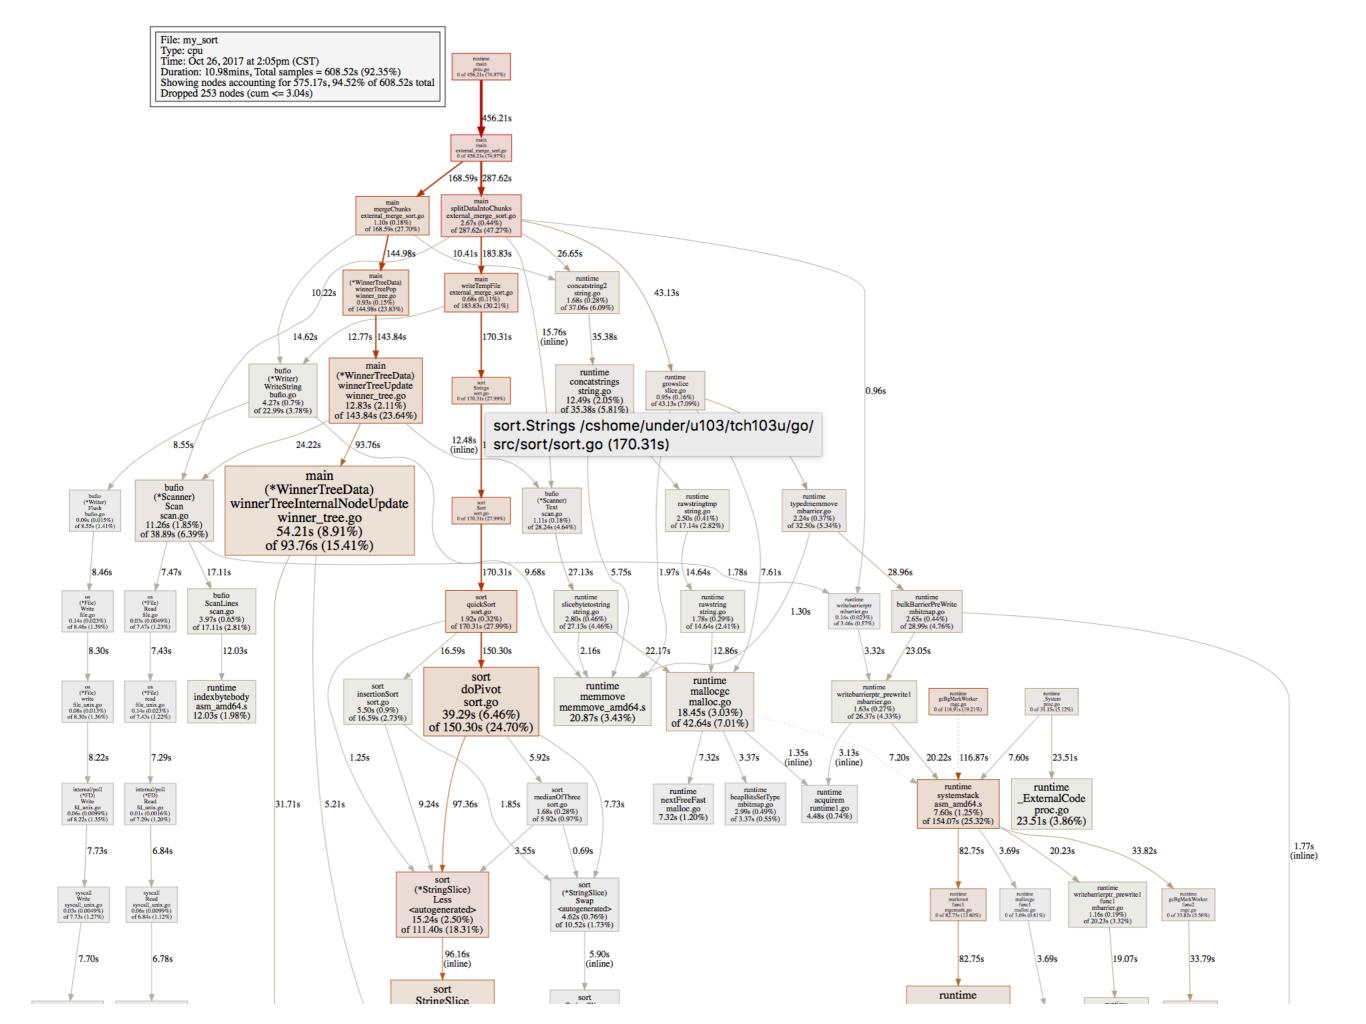
曾俊宏

實作

- External merge sort
 - 先將資料分成指定的run個數
 - 對於每個run先做sorting
 - 平行化
 - 最後利用winner tree進行合併

- 使用 golang 真的太方便了
 - goroutine, Channel!
 - Garbage collection
 - 大推 CPU 和 memory profiler
 - 讓你更敢使用指標
 - 快速compile
 - Error message 簡單易懂



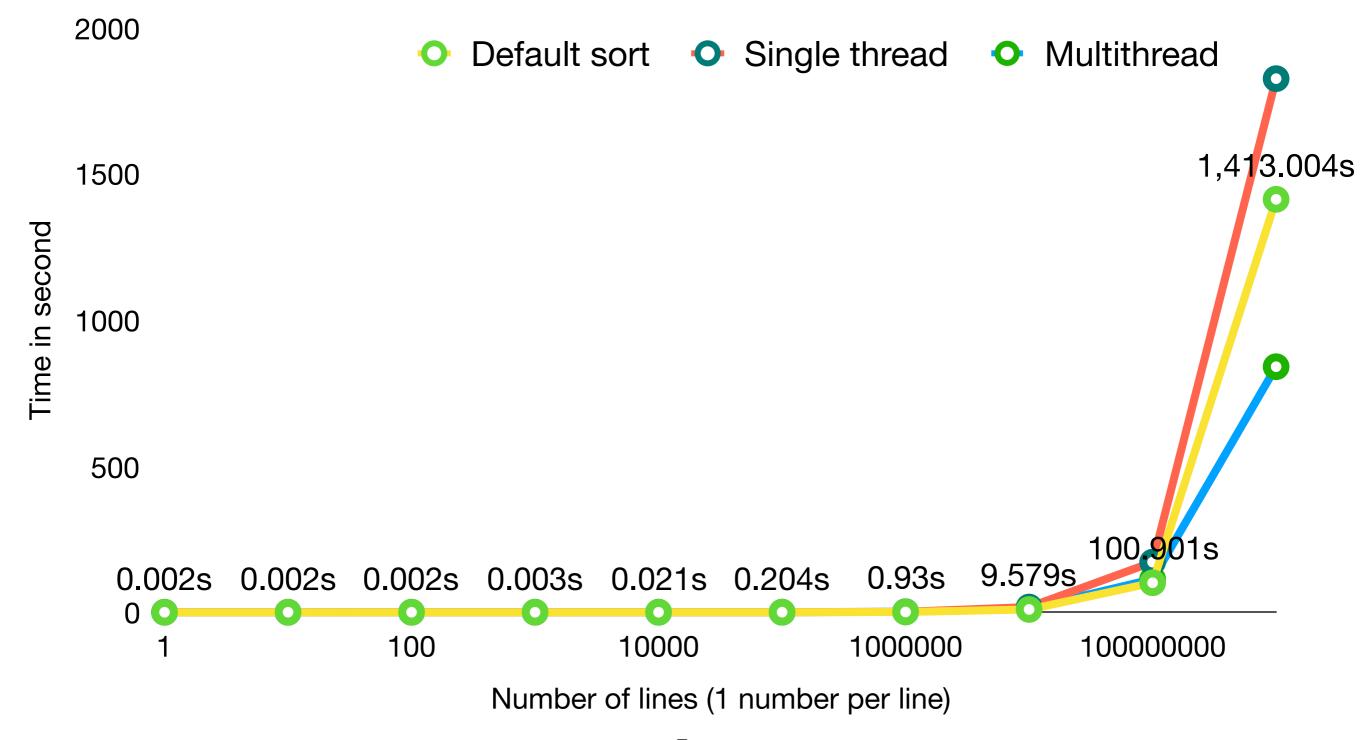


測試

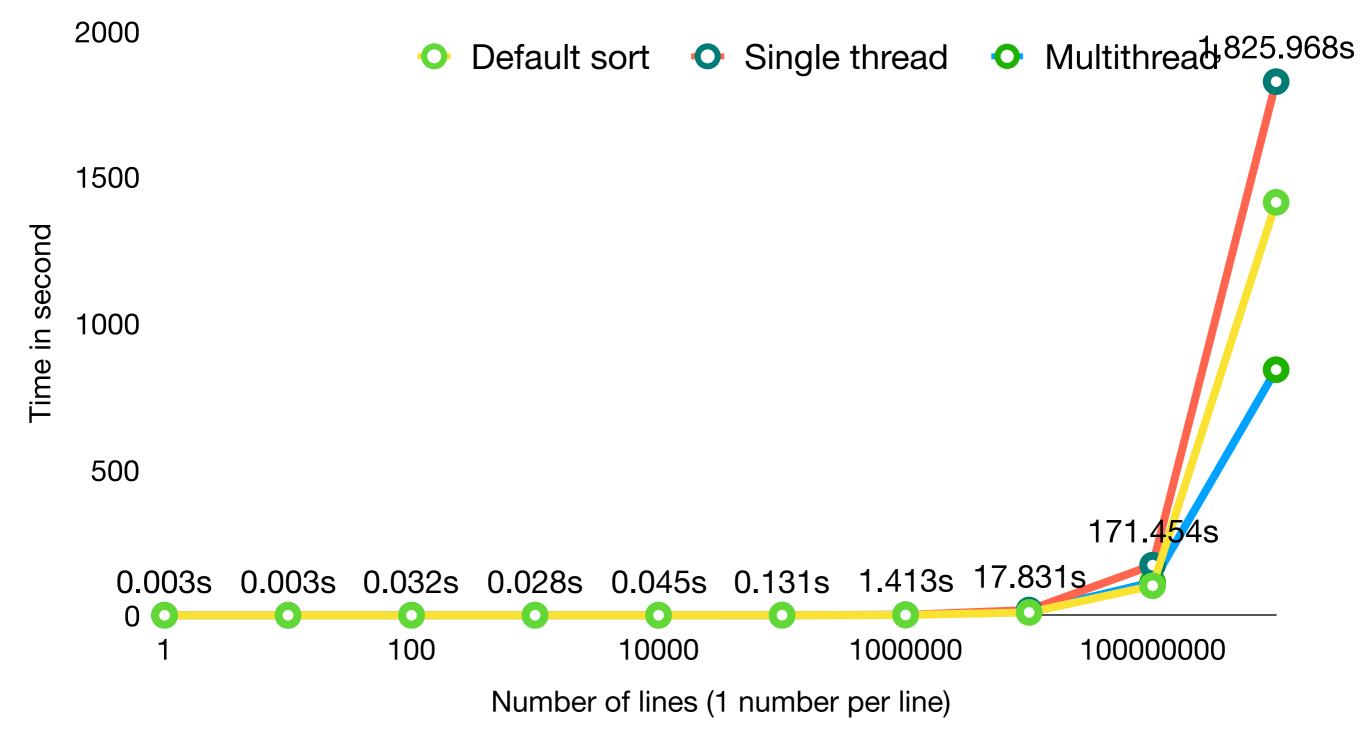
- 使用1到10000000000行數字的檔案
 - for(int ii = 1; ii <= 100000000; ii *= 10)
- 檔案大小最大約為10GB,次大約為1GB
- 利用 sort -c 進行檢查

```
2 git:(master) ./my_sort -h
Parse command line argument
Usage of ./my_sort:
  -chunks int
        Minimal chunks to be created (default 1024)
  -cpuprofile string
        write cpu profile to file
        Set true for debug mode
  -depth int
        Depth (default 4)
  -freq int
        frequency for printing debug messages (default 100)
  -i string
        The file to be sorted (default "in")
  -memprofile file
        write memory profile to file
  -o string
        The file to store sorted result (default "out")
  -p int
        Default to parallel mode (default 1)
  -pi
        Set to true to preserve the input file (default true)
  -pt
        Set to true to preserve the temporary file
  -tmp string
        The path for generated temporary files to be stored (default "/tmp")
```

效能 工學院電腦1 內建的 sorting



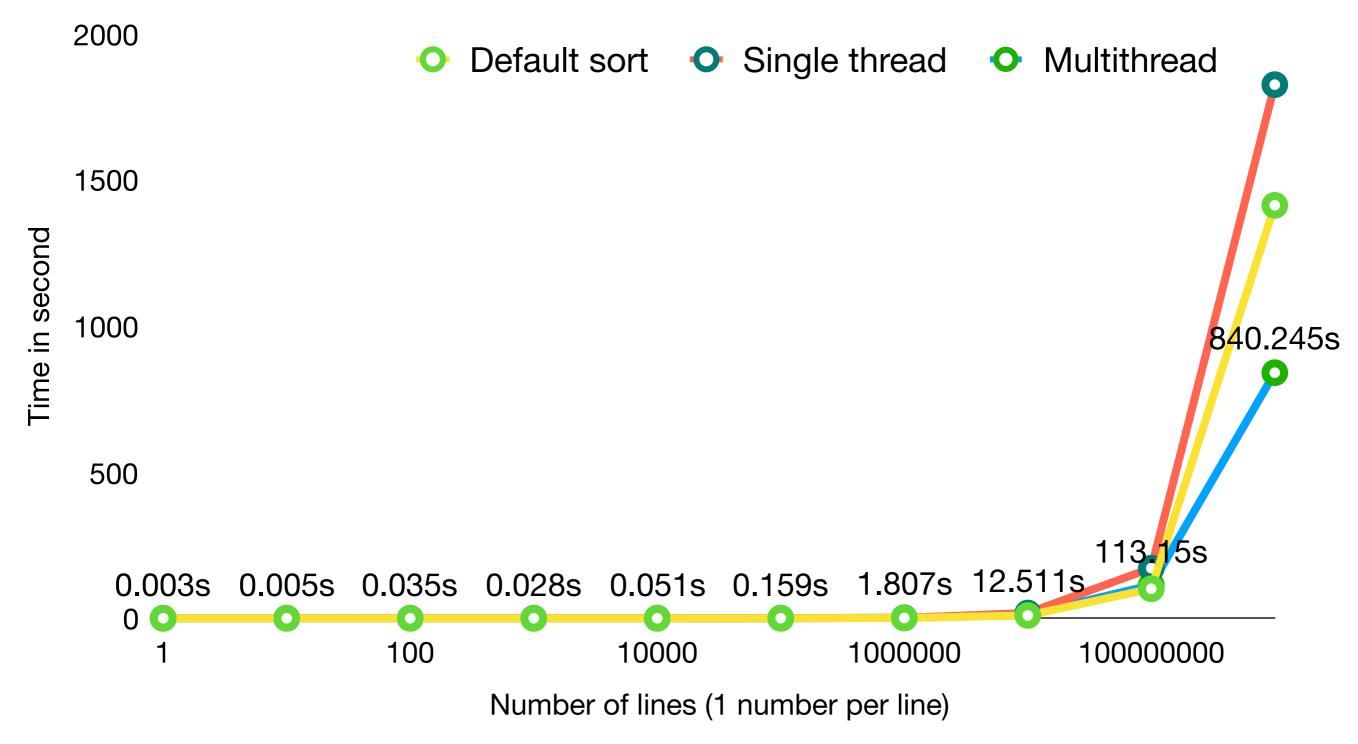
效能 工學院電腦1 單線程sorting



效能

工學院電腦1

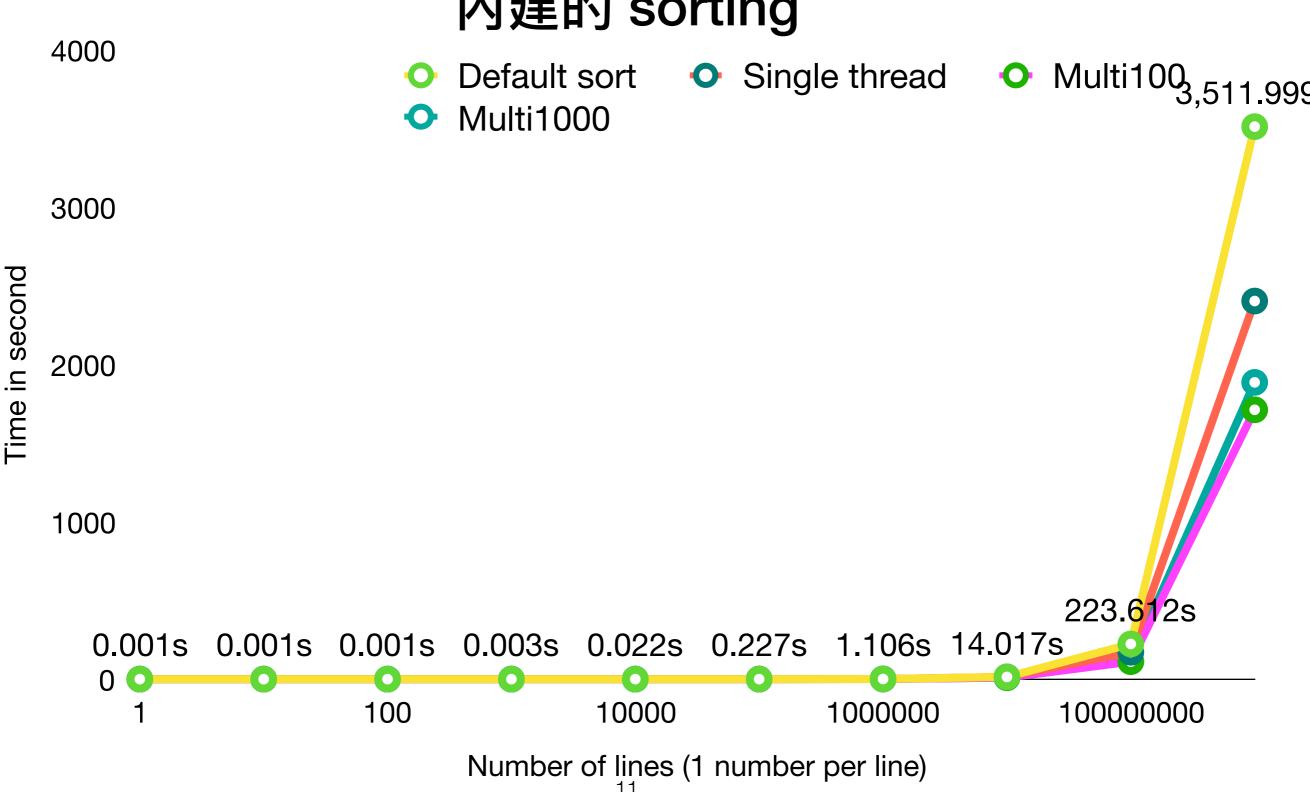
多線程, 100 runs, depth = 6



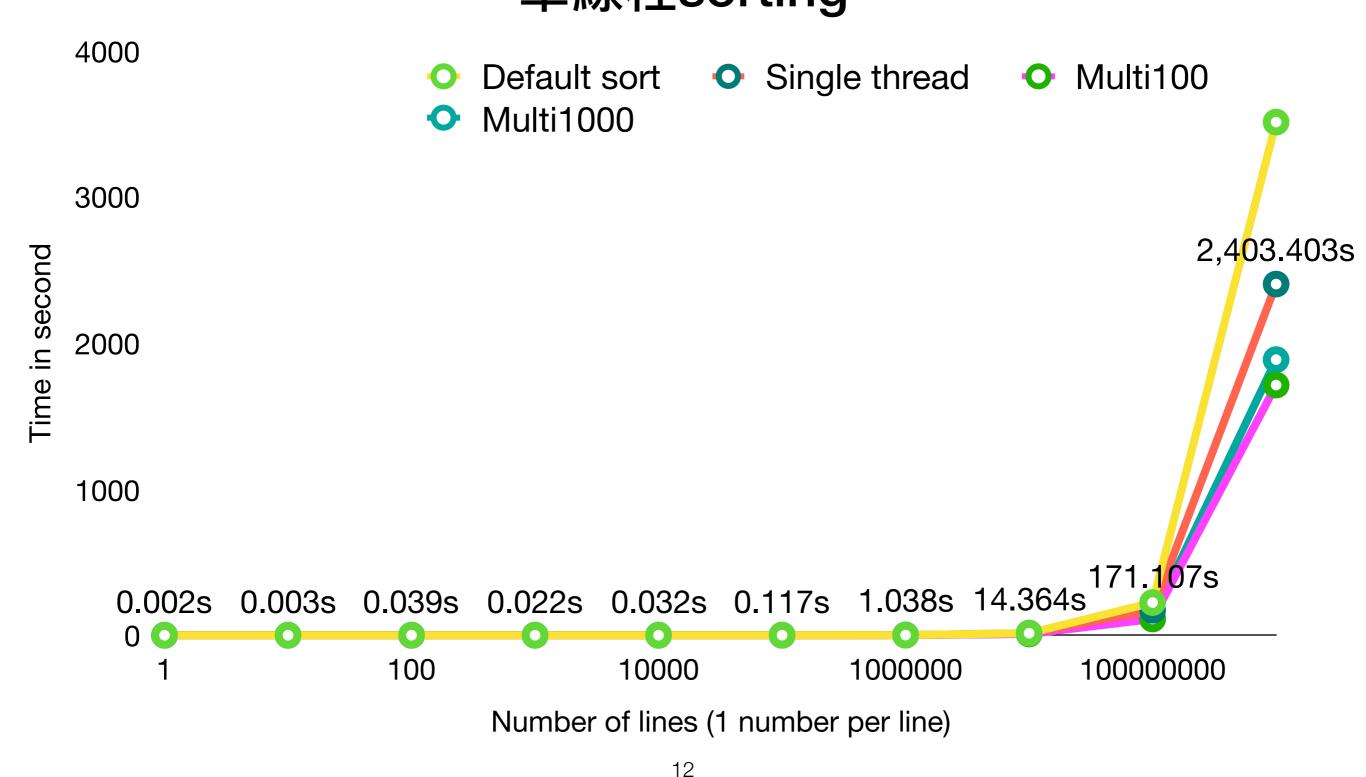
小結

- 工學院電腦 ram 太大,內建 sorting 會比較快一些
 - 我的winner tree貌似有寫爛,跟黃鈺程的比較, performance 大概會慢 20%

效能 <u>linux.cs.ccu.edu.tw</u> 內建的 sorting

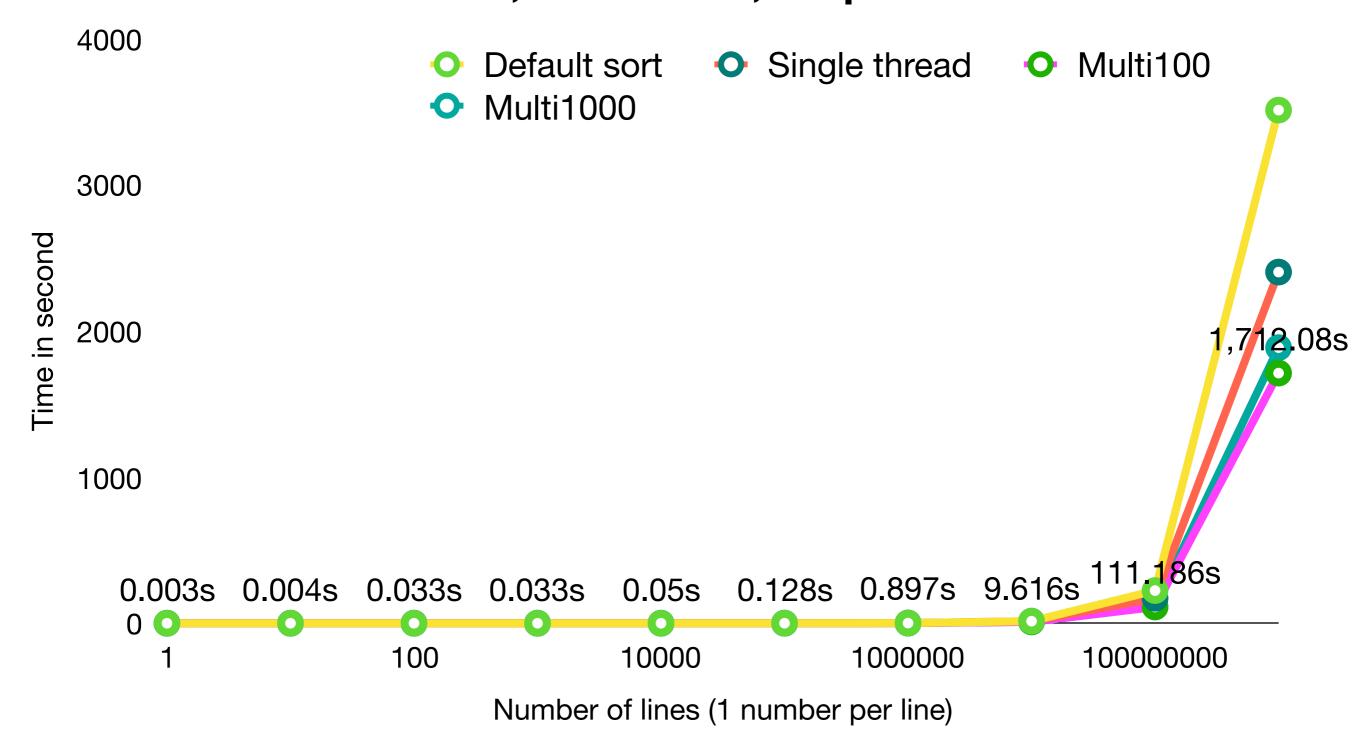


效能 <u>linux.cs.ccu.edu.tw</u> 單線程sorting



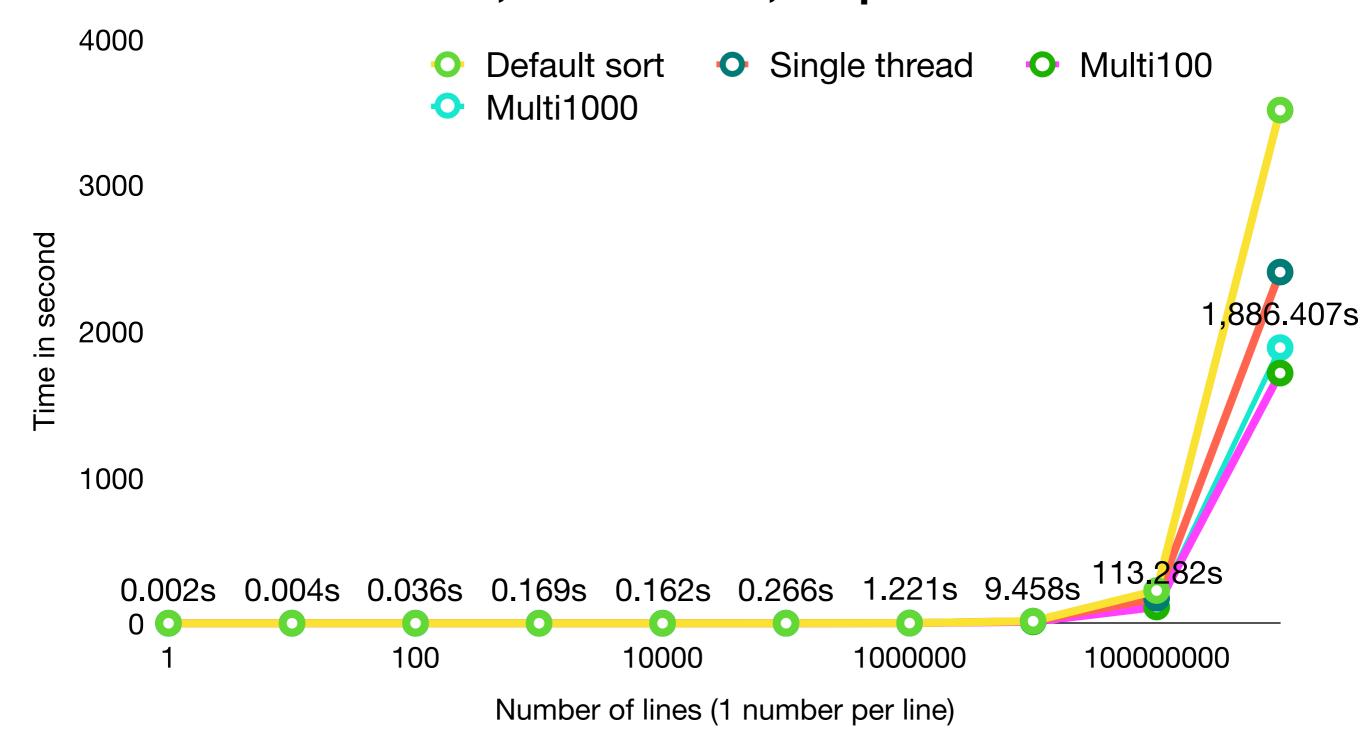
效能

<u>linux.cs.ccu.edu.tw</u> 多線程, 100 runs, depth = 6



效能

<u>linux.cs.ccu.edu.tw</u> 多線程, 1000 runs, depth = 6



小結

- Linux 工作站電腦 ram 不大,內建 sorting 會比較慢一些
- Chunk原則上越少越快,但是受限於記憶體至少也要開個 50 chunks 才不會爆 ram